



Politechnika
Śląska

POLITECHNIKA ŚLĄSKA
WYDZIAŁ AUTOMATYKI, ELEKTRONIKI I INFORMATYKI

Projekt inżynierski

Wykorzystanie sieci neuronowych do detekcji ziaren w obrazach
termowizyjnych

Autor: Maciej Ziaja

Kierujący pracą: dr inż. Sebastian Budzan

Gliwice, styczeń 2020

Streszczenie

Tematem pracy jest...

Deklaracja

Deklaruję że...

Podziękowania

Pragnę podziękować...

Spis treści

1	Wstęp	1
1.1	Motywacja projektu	1
1.2	Cel pracy	1
2	Założenia projektowe i wykorzystane narzędzia	2
2.1	Analizowane pyły rud miedzi	2
2.2	Rodzaje termowizji i idea wykorzystania pomiarów termowizyjnych	2
2.3	Kamera termowizyjna FLIR A320	3
2.3.1	Opis sprzętowy wykorzystywanej kamery	3
2.3.2	Obiektyw kamery	5
2.3.3	Oprogramowanie do obsługi kamery	6
2.4	Narzędzia programistyczne	6
2.4.1	Język programowania Python	6
2.4.2	Biblioteka przetwarzania obrazu Scikit-image	7
2.4.3	Interfejs sieci neuronowych Keras i biblioteka TensorFlow . .	7
3	Analiza i ekstrakcja danych z kamery termowizyjnej	8
3.1	Proces pomiarowy i budowa zbioru danych	8
3.2	Analiza zebranych obrazów termowizyjnych	9
3.2.1	Prezentacja przykładowej serii pomiarowej	9
3.2.2	Przetwarzanie danych wizyjnych	11
3.2.3	Poprawa jakości obrazu	11
3.2.4	Automatyczny odczyt zakresu pomiarowego temperatur z ob- razu	11
3.3	Poszukiwanie zależności użytecznych w klasyfikacji	11
3.3.1	Wybór cech obrazu użytecznych w klasyfikacji	13
3.3.2	Wybór algorytmu detekcji ziaren	15
3.3.3	Algorytm śledzenia ziaren w serii zdjęć	17
3.3.4	Wizualizacja zebranych cech i ocena ich użyteczności	17

4	Prototypowanie sieci neuronowej klasyfikującej ziarna miedzi	18
4.1	Budowa prototypu sieci neuronowej	18
4.1.1	Dobór struktury sieci	18
4.1.2	Trening sieci neuronowej	18
4.2	Walidacja i ocena działania sieci	18
5	Podsumowanie	19

Rozdział 1

Wstęp

1.1 Motywacja projektu

1.2 Cel pracy

Rozdział 2

Założenia projektowe i wykorzystane narzędzia

2.1 Analizowane pyły rud miedzi

2.2 Rodzaje termowizji i idea wykorzystania pomiarów termowizyjnych

Pomiary termowizyjne polegają na rejestracji promieniowania cieplnego obiektów w celu ustalenia ich temperatury. Badania z wykorzystaniem termowizji można podzielić na dwie grupy: *termowizję pasywną* oraz *termowizję aktywną*.

Technika pasywna polega na rejestracji obrazów obiektów bez ingerencji w ich temperaturę w czasie trwania pomiarów. Można w ten sposób obserwować przepływ ciepła w urządzeniach technicznych, procesach przemysłowych oraz biologicznych. W rozważanym w pracy przypadku technika ta nie ma jednak zastosowania. W warunkach pokojowych badany materiał ma w całej swojej objętości podobną temperaturę co skutkuje obrazem równomiernego szumu w rejestrowanym obrazie.

Bardziej zaawansowaną techniką są pomiary z wykorzystaniem termowizji aktywnej. W tym trybie pomiarów badane obiekty nagrzewa się w początkowej fazie pomiaru, w powtarzalnych warunkach, a następnie rejestruje proces ich stygnięcia. Podczas dostarczania ciepła do obiektu oraz jego oddawania na obrazach termowizyjnych można zaobserwować strukturę badanego obiektu. Przedmioty o niejednorodnej i złożonej budowie nagrzewają się oraz stygną nierównomiernie co jest rejestrowane przez kamery termowizyjne. W ten sposób można dostrzec cechy obiektu niewidoczne gołym okiem, takie jak zmiany jego gęstości, składu oraz uszkodzenia struktury. Termowizję aktywną stosuje się szeroko w badaniach naukowych oraz przemyśle. Przykładowe aplikacje tej techniki to wykrywanie defektów

w produktach przemysłowych oraz wykrywanie części konstrukcji podatnych na zużycie. Termowizja aktywna jest techniką niedestruktywną oraz bezkontaktową, co stanowi jej zalety w analizie materiałowej. Technika ta wymaga jednak etapowego procesu pomiarowego, potrzebne jest przygotowanie instalacji grzewczej, a nagrzewanie i stygnięcie materiału może być czasochłonne. Przebieg zmian temperatury najlepiej rejestrować na materiałach wideo, aby zmaksymalizować ilość danych zgromadzonych w trakcie eksperymentu.

2.3 Kamera termowizyjna FLIR A320

Przedmiotem projektu jest analiza obrazów pochodzących z przemysłowej kamery termowizyjnej FLIR A320. Firma FLIR zajmuje się produkcją wysokiej jakości kamer i detektorów do celów profesjonalnych i przemysłowych. Używana kamera łączy wysoką jakość pomiaru z nowoczesnymi funkcjami integracji z oprogramowaniem komputerowym. Urządzenie komunikuje się z komputerem za pomocą kabla ethernetowego, pozwalając na kontrolę z poziomu oprogramowania oraz bibliotek programistycznych. Dodatkowo kamera posiada możliwość planowania automatycznych pomiarów, alarmów, oferuje funkcje analityczne oraz wbudowany serwer internetowy.

2.3.1 Opis sprzętowy wykorzystywanej kamery

Kamera ma postać podłużnego korpusu, do którego swobodnie można podłączać pasujące obiektywy. Na rysunku 2.1 przedstawiono zdjęcie wykorzystywanego urządzenia. Egzemplarz kamery znajdujący się w laboratorium termowizji Politechniki Śląskiej został wyposażony w obiektyw, pozwalający oglądać ziarna rud miedzi w powiększeniu. Kamera cechuje się następującymi parametrami:

- typ detektora: niechłodzony mikrobolometr
- rozdzielczość: 320 na 240 pikseli,
- częstotliwość odświeżania: 9Hz do 30Hz
- szerokość otworu: $f1.3$,
- autofokus z wbudowanym silnikiem,
- zakres pomiarowy temperatur:
 1. od -15°C do 50°C ,
 2. od 0°C do 350°C ,



Rysunek 2.1: Kamera termowizyjna FLIR A320

- dokładność: $\pm 2^{\circ}\text{C}$ lub $\pm 2\%$ odczytu,
- zakres wykrywanego widma promieniowania: $7.5\mu\text{m}$ do $13\mu\text{m}$.

Kamera wykrywa temperaturę przez detektor zwany *bolometrem*, który mierzy energię niesioną przez fale elektromagnetyczne w spektrum podczerwieni. Kiedy fala pada na detektor kamery, temperatura komórek matrycy rośnie i zwiększa się ich rezystancja elektryczna, co wpływa na natężenie prądu przepływającego przez obwody w czujniku. Wartości natężenia prądu są mierzone, a na ich podstawie określana jest mierzona temperatura.

Zakres temperatur kamery jest odpowiedni do przeprowadzenia eksperymentów z pomiarami metodą termowizji aktywnej. Próbkę planuje się podgrzewać do temperatury maksymalnie około 80°C , wartość ta mieści się w zakresie pracy urządzenia. Dokładność kamery jest zadowalająca, próbne materiały nagraniowe wskazały, że na zdjęciach widocznych jest wiele szczegółów i detali badanego materiału. Przy klasyfikacji obrazów i wzorców stygnięcia próbek jest to bardziej istotne niż liczbową dokładność pomiarową przyrządu.

W porównaniu ze zwykłymi, współczesnymi aparatami rozdzielczość kamery termowizyjnej może wydawać się bardzo mała. Należy sobie jednak uzmysłwić, że w standardowych aparatach piksele mają rozkład Bayera, a wartości składowych koloru są interpolowane. W kamerze termowizyjnej każdy piksel dokonuje pełnego pomiaru wartości temperatury, dlatego bezpośrednie porównanie rozdzielczości używanego przyrządu z popularnymi aparatami może być mylące. Oczywi-

ście większa rozdzielczość kamery byłaby pożądana, jednak jej obecne możliwości pozwalają na szczegółowe pomiary i obserwacje wielu detali ziaren rud miedzi.

2.3.2 Obiektyw kamery

Kamerę wyposażono w obiektyw zbliżeniowy FLIR T19741, pozwalający obserwować ziarna rud miedzi. Jest to sprzęt zaprojektowany przez producentów używanej kamery i dedykowany pracy z urządzeniami termowizyjnymi. Przyrząd przedstawiono na rysunku 2.2. Wybrany obiektyw jest przygotowany z myślą o obserwacji



Rysunek 2.2: Obiektyw FLIR T197415

drobnych detali powierzchni w dużym zbliżeniu. Używany model ma następujące parametry:

- ogniskowa: 18.2mm,
- powiększenie: 1×1 ,
- pole widzenia: 8mm na 6mm,
- odległość od płaszczyzny ostrzenia: 20mm,
- głębia ostrości: 0.3mm,
- przysłona: bez regulacji, równa otworowi systemu montażu kamery,
- budowa: trzy soczewki asferyczne.

Zgodnie ze specyfikacją producenta obiektyw ma powiększenie 1×1 , co może wydawać się niedużą wartością. Należy mieć jednak świadomość, że zwykłe obiektywy zmniejszają obraz padający na matrycę, powszechnie przyjmuje się jako granicę makrofotografii powiększenie 1×1 . W obserwacji ziaren i detali powierzchni nie jest jednak istotne powiększenie, ale to że używany obiektyw jest *zbliżeniowy*. Oznacza to, że ma on bardzo małą odległość ostrzenia, czyli można go przysunąć blisko obserwowanej powierzchni. Obiektyw zbliżeniowy pozwala na obserwację z dystansu 20mm, typowe obiektywy ostrzą z odległości parudziesięciu centymetrów do ponad metra. Dzięki temu obiektyw zbliżeniowy pozwala na obserwację bardzo drobnych detali powierzchni.

2.3.3 Oprogramowanie do obsługi kamery

Jedną z najważniejszych cech kamery jest łatwość jej integracji z oprogramowaniem komputerowym. Kamere można obsługiwać za pomocą programu FLIR Tools. Pozwala on na podgląd obrazu oraz wykonywanie zdjęć termowizyjnych. Producent dostarcza również bibliotekę LabVIEW pozwalającą na zaawansowaną pracę z kamerą. Do obsługi stanowiska został napisany program używający tych bibliotek, który pozwala na nagrywanie materiałów wideo przy pomocy kamery. Nagrane materiały mają własnościowy format firmy FLIR, jednak można je odtwarzać w programie FLIR Tools. Program pozwala także na eksport stopklatek z nagrania, w postaci plików JPEG. Przy obsłudze narzędzia ważne jest ustawianie zakresu temperatur na obrazie. Wybrany zakres decyduje w jaki sposób wartości temperatury są mapowane na kolory w obrazie zawarte w tablicy LUT. Program oferuje tablice w skali szarości, takie zostały użyte w projekcie, możliwy jest także wybór tablic w postaci kolorowych gradientów. Wybór zakresu wpływa na wygląd wyświetlanego obrazu oraz eksportowanych stopklatek. Jego nieodpowiedni dobór może skutkować zbyt ciemnym, jasnym, lub mało kontrastowym obrazem. Aby zapewnić najlepsze wykorzystanie nagrań z kamery oraz powtarzalny charakter eksportu stopklatek korzystano z opcji automatycznego doboru zakresu temperatur, jaki jest wbudowany w program FLIR Tools.

2.4 Narzędzia programistyczne

2.4.1 Język programowania Python

Założenia projektu wymagają użycia języka programowania pozwalającego na zaawansowaną obróbkę obrazu oraz wydajne budowanie sieci neuronowych. W obu tych dziedzinach wiodącym językiem jest Python, posiadający bogaty zestaw bibliotek. Język ten oferuje dużą wygodę programowania, co jest istotne przy proto-

typowaniu oraz pracy badawczej. Jednocześnie Python jest zaopatrzony w wydajną bibliotekę obliczeń numerycznych NumPy. Oferuje ona klasy macierzy numerycznych oraz bogaty zestaw operacji matematycznych. Macierze biblioteki NumPy są mniej elastyczne niż zwykłe listy języka Python, jednak oferują dużo większą wydajność obliczeniową, między innymi dzięki wsparciu obliczeń wektorowych na różnych procesorach. Wiele innych bibliotek wykorzystuje pakiet NumPy, na przykład przy przetwarzaniu obrazów, co pozwala na wysoką wydajność obliczeń. Połączenie wygody programowania z zadowalającą wydajnością bibliotek numerycznych, sprawia że język Python jest dobrym wyborem do realizacji założeń projektu.

2.4.2 Biblioteka przetwarzania obrazu Scikit-image

Język Python oferuje bogaty zestaw bibliotek przetwarzania obrazu. Najbardziej popularną z nich jest biblioteka OpenCV napisana w języku C++. Zdecydowano się jednak na wybór mniej znanego pakietu Scikit-image. Jest to biblioteka nastawiona bardziej na obliczenia naukowe i badawcze oraz napisana bezpośrednio z myślą o języku Python. Scikit-image, w porównaniu z OpenCV, oferuje bardziej spójny interfejs programisty oraz lepiej wykorzystuje charakterystykę języka Python. Dodatkowo wybrana biblioteka jest częścią zestawu Scikit, w skład którego wchodzi pakiet Scikit-learn służący do uczenia maszynowego. Może on być przydatny przy tworzeniu sieci neuronowej, a spójność bibliotek z pakietu Scikit jest niewątpliwie zaletą. Wybrana biblioteka charakteryzuje się również dobrą dokumentacją oraz zestawem przydatnych przykładów.

2.4.3 Interfejs sieci neuronowych Keras i biblioteka TensorFlow

Wybór bibliotek głębokiego uczenia w języku Python jest bardzo szeroki. Do najpopularniejszych pakietów należą: Keras, TensorFlow oraz PyTorch. Zdecydowano się na wybór interfejsu biblioteki Keras. Jest to pakiet nastawiony na elastyczność i możliwość eksperymentowania, oferuje wysokopoziomową, matematyczną warstwę abstrakcji opisu sieci neuronowych. Keras nie jest jednak pełnym rozwiązaniem, a raczej abstrakcyjnym interfejsem. Używanie go wymaga wyboru wewnętrznego silnika biblioteki. Zdecydowano się na wybór domyślnej opcji i użycie zaplecza pakietu TensorFlow.

Rozdział 3

Analiza i ekstrakcja danych z kamery termowizyjnej

3.1 Proces pomiarowy i budowa zbioru danych

Zgodnie z opisem technik termowizyjnych przedstawionym w sekcji 2.2 zdecydowano się na przeprowadzenie pomiarów za pomocą termowizji aktywnej. Aby zrealizować pomiary uprzednio przygotowano stanowisko laboratoryjne. Kamera termowizyjna została umieszczona na statywie, a do ogrzewania próbek zdecydowano się wykorzystać lampę halogenową.

W procesie termowizji aktywnej istotna jest charakter procesu nagrzewania materiału. Przy przygotowaniu pomiarów należało zdecydować przy jakim warunku zakończyć przekazywanie ciepła do próbki. Rozważono dwie możliwości:

- a) ogrzewanie próbek do osiągnięcia ustalonej temperatury,
- b) ogrzewanie próbek przez określony, stały czas.

Zdecydowano się na metodę b), ze względu na wygodę jej realizacji. Doprowadzenie każdej próbki do tej samej temperatury wymagałoby pomiarów w czasie nagrzewania, co jest bardziej wymagające do realizacji. Zgodnie ze wstępnymi obserwacjami nagrzewanie materiału przez określony czas pozwala na obserwację jego cech unikalnych i wzorców zachowania podczas stygnięcia. Następnie należy wybrać czas nagrywania materiałów wideo kamerą. Na podstawie wstępnych obserwacji i próbnych nagrań zdecydowano się na ogrzewanie próbek przez jedną minutę oraz rejestrację ich stygnięcia przez cztery minuty. Taka konfiguracja daje przy badanych pyłach rud miedzi ostry i szczegółowy obraz w początkowej fazie nagrywania oraz widocznie rozmazany i mniej kontrastowy materiał pod koniec stygnięcia próbek. Charakter procesu przejścia między tymi stanami pozwoli na klasyfikację badanych próbek. Ostatnia decyzja kształtująca charakter pomiarów

dotyczy chwili przechwytywania stopklatek z pozyskanych materiałów wideo. Na podstawie obserwacji zdecydowano się eksportować 5 klatek na początku każdej minuty nagrania. Po ustaleniu planu eksperymentu pomiarowego przystąpiono do jego wykonania. Zgodnie z opisem badanych materiałów w sekcji 2.1, zgromadzono materiały wideo dla czterech klas ziaren rudy miedzi. Ze względu na czasochłonność pomiarów dla każdej klasy materiału nagrano trzy materiały wideo. Z pozyskanych nagrań wyeksportowano stopklatki używając programu FLIR Tools, pamiętając o używaniu algorytmu automatycznego doboru zakresu temperatur zgodnie z opisem w podsekcji 2.3.3.


3.2 Analiza zebranych obrazów termowizyjnych

Zgodnie z zamysłem pomiarów przedstawionym w sekcji 3.1 z każdego nagrania wybrano pięć stopklatek. Podczas eksperymentu uzyskano łącznie dwanaście pomiarów, zawierających sumarycznie 60 zdjęć. W ramach uczenia maszynowego jest to bardzo mały zbiór danych, biorąc jednak pod uwagę wstępno-badawczy charakter pracy oraz czasochłonność procesu pomiarowego zdecydowano, że jest to rozmiar zadawalający do pierwszych prób klasyfikacji. Zebrane materiały mają format JPEG, do oznaczania zdjęć przyjęto schemat nazw jak w przykładzie: 115_E11R_1, gdzie człony nazwy oznaczają kolejno:


- automatyczny numer nagrania w programie FLIR Tools,
- klasę próbki,
- minutę nagrania.

3.2.1 Prezentacja przykładowej serii pomiarowej


Jak opisano w rozdziale 3.1 jedna próbka w zbiorze danych składa się z serii pięciu zdjęć o malejącym kontraście i szczegółowości. Na rysunku 3.1 przedstawiono przykładową próbkę 104 klasy E5R. Widoczny jest proces stygnięcia materiału. Skala po prawej stronie obrazów ma malejące na kolejnych obrazach wartości co pokazuje że następuje zmniejszenie temperatury na całym obrazie. Dodatkowo obraz staje się coraz mniej wyraźny i kontrastowy. Ze względu na budowę materiału nagrzana próbka emituje ciepłoze swoich zróżnicowanych struktur w niejednorodny sposób. Wraz z ochłodzeniem próbki jej temperatura się wyrównuje i kamera termowizyjna rejestruje coraz mniej szczegółów. Detale i elementy charakterystyczne obrazu zlewają się na kolejnych zdjęciach, wraz z opadaniem temperatury na zdjęciu pojawia się także coraz więcej szumów.




(a) Obraz z próbki 104_E5R_0




(b) Obraz z próbki 104_E5R_1



(c) Obraz z próbki 104_E5R_2



(d) Obraz z próbki 104_E5R_3



(e) Obraz z próbki 104_E5R_4

Rysunek 3.1: Zdjęcia procesu stygnięcia w przykładowej próbce 104 klasy E5R

3.2.2 Przetwarzanie danych wizyjnych

3.2.3 Poprawa jakości obrazu


3.2.4 Automatyczny odczyt zakresu pomiarowego temperatur z obrazu

Jak wspomniano w sekcji 2.3.3 jednym z kluczowych czynników decydujących o wyglądzie obrazów pochodzących z kamery jest zakres temperatur mapowany na kolory w obrazie. Niestety aplikacja FLIR Tools nie pozwala na eksport zakresu temperatur wraz ze zdjęciami w formie liczbowej. W czasie zapisu zdjęć oprogramowanie dodaje na nich interfejs z aktywną skalą pomiarową, jednak jest on graficznie naniesiony na obraz. Aby ułatwić w przyszłości pracę z materiałami z kamery opracowano dodatkowo mechanizm ekstrakcji zakresu temperatur z zdjęć pochodzących z kamery.

W celu konstrukcji funkcji odczytu wartości liczbowych z obrazu posłużono się gotową siecią neuronową zaprojektowaną do detekcji tekstu na zdjęciach. Zdecydowano się na użycie popularnej biblioteki *Pytesseract*. Aby poprawnie odczytać wartości z obrazu najpierw przycięto je tak by w kadrze znajdowała się tylko odczytywana liczba. Ponieważ przy eksporcie zdjęć program FLIR Tools nakłada interfejs na zdjęcia w identyczny sposób, kadrowanie obrazu jest takie same dla każdej próbki pomiarowej. Wycięte kadry są bardzo małej rozdzielczości, aby ułatwić sieci rozpoznawanie liczb zdecydowano się przeskalować je w górę. W czasie skalowania włączono mechanizm anty aliasingu aby wyrównać krawędzie cyfr. Ponieważ używana sieć uznaje za tło kolor biały oraz poszukuje liczb w kolorze czarnym barwy na zdjęciu odwrócono. Następnie obraz poddano binaryzacji metodą *otsu*. Jest to popularna i wydajna metoda binaryzacji, jej efektywność jest maksymalna kiedy ilość pikseli tła oraz pierwszego planu jest zbliżona, dlatego poprawne kadrowanie liczb sprzyja jakości ich binaryzacji[1]. Na rysunku 3.2 przedstawiono kolejne etapy przygotowania obrazu do rozpoznania liczb. Implementację opisanego mechanizmu odczytywania zakresu temperatur ze zdjęć przedstawiono na listingu 1.

3.3 Poszukiwanie zależności użytecznych w klasyfikacji

Aby móc klasyfikować dane należy zastanowić się nad cechami które je odróżniają. Na rysunku 3.3 przedstawiono porównanie stygnięcia dwóch rodzajów próbek: E5R oraz E6R. W klasyfikacji użyteczne będą dane które są unikalne dla danej klasy. Ponieważ dane stanowią serię obrazów postępującego studzenia materiału, aby wykorzystać pełnię możliwości zebranych zdjęć warto szukać cech charakterystycznych



(a) Przeskalowany kadr z liczbą



(b) Kadr z liczbą po binaryzacji

Rysunek 3.2: Przygotowanie zakresu temperatur do odczytu przez sieć neuronową

```
def get_temperature_bounds(img, bounds=((6, 24), (283, 318)),  
                             ((219, 236), (283, 318))):  
    '''Extract temperature values from FLIR UI on image.'''  
    img = invert(img)  
    temp_txt = []  
    for bound in bounds:  
        bound_img = img[slice(*bound[0]), slice(*bound[1])]  
        bound_img = rescale(bound_img, 4, anti_aliasing=True)  
        thr = threshold_otsu(bound_img)  
        img_txt = bound_img > thr  
        img_txt = Image.fromarray(img_txt)  
        temp = pytesseract.image_to_string(img_txt)  
        if temp is not '':  
            temp = float(temp)  
        else:  
            temp = 0  
        temp_txt.append(temp)  
    return temp_txt
```

Listing 1: Funkcja języka Python do odczytywania zakresu temperatur ze zdjęć z kamery


dla przebiegu procesu chłodzenia.

3.3.1 Wybór cech obrazu użytecznych w klasyfikacji

Po przyjrzeniu się rysunkowi 3.3 widoczne jest, że w próbce E6R temperatura ziaren zaczęła wyrównywać się szybciej. Na podstawie obserwacji zebranych danych rozpatrzono następujące możliwości obserwacji cech charakterystycznych materiałów:


- a) klasyfikacja zdjęć w całości jako macierzy danych przez złożoną sieć konwolucyjną,
- b) analiza częstotliwościowa obrazów w celu śledzenia tempa rozmycia kolejnych zdjęć,
- c) użycie macierzy GLCM jako wejścia sieci neuronowych,
- d) wykrywanie krawędzi ziaren i wyznaczanie reprezentacji liczbowej ich kształtów oraz powierzchni,
- e) śledzenie zlewania się i zanikania małych detali na obrazie.

Wszystkie przedstawione opcje mają uzasadnienie i mogą sprawdzić się dobrze jako podstawa klasyfikacji. Należy jednak ocenić której z nich użyć w pierwszej próbie konstrukcji klasyfikatora. Metoda a), z użyciem sieci konwolucyjnych może wykorzystywać najnowsze rozwiązania w dziedzinie uczenia maszynowego, jednak przy jej użyciu na przeszkodzie może stać bardzo mały rozmiar zbioru uczącego. Na niewielu zgromadzonych obrazach znajduje się wiele informacji i szumów, a złożoność jednego zdjęcia jest na tę chwilę nieproporcjonalna do wielkości zbioru danych. Pomysł ten można spróbować zrealizować po rozszerzeniu pomiarów. Kolejna opcja b) z użyciem analizy częstotliwościowej wymaga złożonych operacji matematycznych i może być wrażliwa na szum na obrazie. Po analizie innych opcji zdecydowano, że istnieją bardziej obiecujące alternatywy. Macierz glcm (*Gray-Level Co-Occurrence Matrix*), na której może bazować opcja c), to tablica zawierająca informacje o relacjach wszystkich par pikseli na obrazie. Pozwala ona na analizę takich wartości jak: kontrast, korelacja, energia oraz homogeniczność. Jest to opcja dająca możliwość analizy dużej ilości informacji, z pewnością warta rozpatrzenia, jednak dosyć skomplikowana. Na obrazie można także wykrywać kształty ziaren za pomocą filtrów detekcji krawędzi. Opcję tę testowano przy pomocy filtra *Canny*. Krawędzie ziaren okazały się jednak trudne do wykrycia kształtów i dalszej segmentacji ze względu na małą rozdzielczość oraz duże upakowanie ziaren. Operacje morfologiczne domykania kształtów powodowały bardzo duże zmiany w obrazie i zlewały ziarna. Rozwój takiego podejścia przy analizowanych obrazach wymaga



Rysunek 3.3: Porównanie procesu stygnięcia próbek klasy E5R oraz E6R

zaawansowanej i ostrożnej obróbki zdjęć. Ostatnia opcja e) wynika z obserwacji detali na obrazach. Na przedstawionych zdjęciach próbek można zauważyć drobne ciemne punkty, które są obszarami o wolniejszej wymianie ciepła z otoczeniem niż reszta powierzchni ziaren. Na rysunku 3.4 przedstawiono zbliżenie na grupę takich detali, w czterech częściach procesu stygnięcia. Analizując próbki można zauwa-



Rysunek 3.4: Zbliżenie na charakterystyczne grupy detali materiału

żyć, że wraz ze stygnięciem ciemne punkty w grupach zlewają się, a następnie zanikają. Dodatkowo ich liczba na poszczególnych klasach materiałów jest różna. Zdecydowano się na wybór metody polegającej na śledzeniu liczby tych punktów i ich zaniku. Taka analiza wiąże się z przetwarzaniem obrazów i utworzeniem algorytmów śledzenia detali. Opcja ta wydaje się jednak obiecująca, ponieważ nawet podczas wstępnej obserwacji próbek można dopatrywać się zależności między klasami a obecnością omawianych detali.

3.3.2 Wybór algorytmu detekcji ziaren

Zgodnie z rozważaniami przedstawionymi w podsekcji 3.3.1 w celu klasyfikacji ziaren zdecydowano się na obserwację ilości ciemnych, drobnych detali na obrazach. Należy więc wybrać metodę detekcji charakterystycznych punktów. W wykrywaniu omawianych detali użyteczne są algorytmy wykrywania plam na podstawie analizy pochodnych wartości na obrazie. Biblioteka Scikit-image udostępnia trzy algorytmy tego typu wykorzystujące:

- a) laplasjan funkcji Gaussa,
- b) różnica funkcji Gaussa,
- c) wyznacznik Hesjanu.

Metoda bazująca na laplasjanie funkcji Gaussa jest najdokładniejsza, ale także najwolniejsza. Funkcja Gaussa, której wykres ma charakterystyczny kształt krzywej dzwonowej jest dana wzorem 3.1, gdzie:

- σ to odchylenie standardowe,
- μ to wartość średnia.

$$P(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2} \quad (3.1)$$

Laplasjan to operator różniczkowy drugiego rzędu. Omawiany algorytm oblicza wartości funkcji Gaussa dla coraz większego odchylenia standardowego i układa je w sześcianie. Poszukiwane plamy to lokalne maksima w tym sześcianie. Wadą tego rozwiązania jest bardzo wolne wykrywanie dużych plam z powodu złożoności obliczeniowej.

Różnica funkcji Gaussa jest metodą podobną do poprzedniej. Ponownie rozmywa ona obrazu z narastającymi odchyleniami standardowymi z użyciem funkcji Gaussa. Następnie różnice rozmytych obrazów są układane w sześcianie, gdzie maksima to plamy. Metoda ta jest szybsza i mniej dokładna od algorytmu bazującego na laplasjanie funkcji Gaussa, ale podobnie jak ona jest wolna w wykrywaniu dużych elementów.

Ostatnia metoda jest najszybsza, ale najmniej dokładna. Polega ona na wyszukiwaniu maksimów w macierzy Hesjanu, jest to macierz drugich pochodnych cząstkowych. Postać takiej macierzy w n -wymiarowej przestrzeni przedstawia wzór 3.2. Prędkość tej metody nie zależy od wielkości wykrywanych plam, ale małe elementy mogą nie zostać przez nią wykryte.

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \quad (3.2)$$

Porównanie działania wymienionych metod przedstawiono na grafice 3.5. Jak można było spodziewać się po opisie funkcji najlepsza okazała się metoda Laplasjanu funkcji Gaussa. Funkcję korzystającą z wyznacznika Hesjanu należy odrzucić, ponieważ w rozważanym przypadku istotne jest wykrywanie małych plam. Z tego samego powodu korzystne jest użycie najbardziej dokładnej funkcji. Ponieważ program nie ma wykrywać dużych elementów nie ma ryzyka zbyt powolnych obliczeń na obszernych plamach.

Aby wybrana funkcja laplasjanu funkcji Gaussa wykrywała, zgodnie zamierzeniami tylko małe plamy należy podać jej odpowiednie parametry, co uczyniono



Rysunek 3.5: Porównanie bibliotecznych algorytmów wykrywania plam w obrazie

już na etapie porównania metod detekcji. Wywołanie omawianej funkcji ma postać: `blobs = blob_dog(img, max_sigma=2, threshold=0.1)`. Funkcji podano dwa dodatkowe argumenty, które są istotne dla pożądanego działania. Argument `max_sigma=2` ogranicza odchylenie standardowe obliczanych funkcji Gaussa, przez co wykrywane są tylko małe elementy. Drugi argument `threshold=0.1` decyduje o poziomie powyżej jakiego punkt jest uznany za maksimum w sześciu laplasjanów. Domyślna wartość tego argumentu `threshold=2.0` okazała się za duża, zmniejszono jej wartość aby wykrywać bardziej subtelne detale. Na podstawie opisanego wywołania metody Laplasjanu funkcji Gaussa opracowano funkcję zwracającą położenie i promień wykrytych plam.

3.3.3 Algorytm śledzenia ziaren w serii zdjęć

3.3.4 Wizualizacja zebranych cech i ocena ich użyteczności

Rozdział 4

Prototypowanie sieci neuronowej klasyfikującej ziarna miedzi

4.1 Budowa prototypu sieci neuronowej

4.1.1 Dobór struktury sieci

4.1.2 Trening sieci neuronowej

4.2 Walidacja i ocena działania sieci

Rozdział 5

Podsumowanie

Spis rysunków

2.1	Kamera termowizyjna FLIR A320	4
2.2	Obiektyw FLIR T197415	5
3.1	Zdjęcia procesu stygnięcia w przykładowej próbce 104 klasy E5R . .	10
3.2	Przygotowanie zakresu temperatur do odczytu przez sieć neuronową	12
3.3	Porównanie procesu stygnięcia próbek klasy E5R oraz E6R	14
3.4	Zbliżenie na charakterystyczne grupy detali materiału	15
3.5	Porównanie bibliotecznych algorytmów wykrywania plam w obrazie	17

Spis tablic

Spis listingów

1	Funkcja języka Python do odczytywania zakresu temperatur ze zdjęć z kamery	12
---	-----------------------------------------------------------------------------------------	----

Bibliografia

- [1] Bülent Sankur Mehmet Sezgin. Survey over image thresholding techniques and quantitative performance evaluation. *Journal of Electronic Imaging*, 13(1):146–165, 2004.